

# ToolUseProxy

AIのツール操作を、実行前に検査する

## AIに任せる作業にも、

頼んだ作業の途中で、  
何が外へ送られるのか。

非公開の設計メモを参考に、公開用の説明資料を作ってもらう。書き直された資料に、外へ出したくない内容まで残っていたら？

「このメモを読んで、  
公開用の説明資料を作って」

**読む**      非公開の設計メモを参照する

**作る**      内容をもとに、別の資料へ書き直す

**送る**      作った資料を外部へ公開する

## 送る内容だけでなく、そこまでの作業をたどる

ToolUseProxyはCodexが使ったツールの記録から、「どの情報を参照し、何を作り、それをどこへ送ろうとしているか」という依存関係をモデルで推定します。

元の文章がそのまま含まれる場合だけでなく、別のファイルへ情報が移る経路も調べます。ただし、言い換えや多段階の加工を必ず検出できるという保証はありません。

# 外へ出したくない情報がある。

## 情報の流れを、 ノードとエッジで表す。

ToolCallを一本の文字列として扱わず、情報の役割と版を分けて、外部送信までの経路を組み立てます。



## グラフ上の一例




eventは情報そのものではなく、「いつ、どの操作で生じたか」を並べる時間軸です。

## 近縁研究・基盤との位置づけ

|                          |                                             |                             |
|--------------------------|---------------------------------------------|-----------------------------|
| AgentArmor<br>(2025)     | 実行traceをCFG・DFG・PDG化して型<br>検査               | ToolCallと送信入力を実行前に判断        |
| CaMeL (2025)             | 信頼済みqueryから制御・data flowを<br>抽出              | 既存agentのtool境界へ後付け          |
| Zep / Graphiti<br>(2025) | 時間付き知識graphとagent memory                    | 記憶検索ではなく送信判断の<br>provenance |
| NeuroTaint<br>(2026)     | 実行履歴を事後解析し意味・因果を追<br>跡                      | Hookで見えるsinkを実行前に判定         |
| FLOWSEAL<br>(2026)       | provenance、IFC lattice、<br>declassification | 実payload・証拠種別・観測限界を重視       |

# 観測した事実と推定を分けて、 エッジを張る。

単に時刻が近いだけでは結びません。操作構造、内容対応、モデル推定を別の証拠として記録します。



# 秘密に由来する手順書は停止。 案内だけなら送信できた。

非公開の研究メモから組立手順書を作り、GitHubへ送ろうとする一連の操作を収録しました。

2026-09-24 / v0.2.0-alpha.16

研究メモを参照して、組立手順書を作成



手順書を含むpushを実行前に停止



無関係な来場者案内だけのcommitへ作り直す



GitHubへのpushに成功

## 停止後に内容を分け、公開作業を再開

assembly\_guide.md を含むpushは、秘密情報源からの経路ありとして実行前に停止しました。無関係な visitor\_info.md だけのcommit a656339 に作り直すと、pushは成功しました。

### ログで裏付けた点

23:41:52にブロック判定、23:46:52にpushの成功応答を記録。この一例は、すべての言い換えや送信経路での動作を保証するものではありません。



#### 実装と検証記録を公開

詳しい説明はチラシでも読めます。  
[github.com/mani1261790/ToolUseProxy](https://github.com/mani1261790/ToolUseProxy)