

AIに任せる作業にも、外へ出したくない情報がある。

頼んだ作業の途中で、
何が外へ送られるのか。

非公開の設計メモを参考に、公開用の説明資料を作ってもら。書き直された資料に、外へ出したくない内容まで残っていたら？

「このメモを読んで、
公開用の説明資料を作って」

読む

非公開の設計メモを参照する

作る

内容をもとに、別の資料へ書き直す

送る

作った資料を外部へ公開する


送る内容だけでなく、そこまでの作業をたどる

ToolUseProxyはCodexが使ったツールの記録から、「どの情報を参照し、何を作り、それをどこへ送ろうとしているか」という依存関係をモデルで推定します。

元の文章がそのまま含まれる場合だけでなく、別のファイルへ情報に移る経路も調べます。ただし、言い換えや多段階の加工を必ず検出できるという保証はありません。

観測した事実と推定を分けて、
エッジを張る。

単に時刻が近いだけでは結びません。操作構造、内容対応、モデル推定を別の証拠として記録します。



情報の流れを、
ノードとエッジで表す。

ToolCallを一本の文字列として扱わず、情報の役割と版を分けて、外部送信までの経路を組み立てます。

保護情報の断片
登録文書を、段落や項目などの比較単位へ分割。

操作データの断片
ToolCallの入力・出力を、query、content、stdoutなどへ分割。

ファイルの版
読み書き後のファイル状態を、同じpathでも版ごとに区別。

外部送信候補
Git push、HTTP、MCP、最終応答など、外へ出る境界。

グラフ上の一例



eventは情報そのものではなく、「いつ、どの操作で生じたか」を並べる時間軸です。

近縁研究・基盤との位置づけ

AgentArmor (2025)	実行traceをCFG・DFG・PDG化して型検査	ToolCallと送信入力を実行前に判断
CaMeL (2025)	信頼済みqueryから制御・data flowを抽出	既存agentのtool境界へ後付け
Zep / Graphiti (2025)	時間付き知識graphとagent memory	記憶検索ではなく送信判断のprovenance
NeuroTaint (2026)	実行履歴を事後解析し意味・因果を追跡	Hookで見えるsinkを実行前に判定
FLOWSEAL (2026)	provenance、IFC lattice、declassification	実payload・証拠種別・観測限界を重視

秘密に由来する手順書は停止。
案内だけなら送信できた。

非公開の研究メモから組立手順書を作り、GitHubへ送ろうとする一連の操作を収録しました。

2026-09-24 / v0.2.0-alpha.16



停止後に内容を分け、公開作業を再開

assembly_guide.md を含むpushは、秘密情報源からの経路ありとして実行前に停止しました。無関係な visitor_info.md だけのcommit a656339 に作り直すと、pushは成功しました。

ログで裏付けた点

23:41:52にブロック判定、23:46:52にpushの成功応答を記録。この一例は、すべての言い換えや送信経路での動作を保証するものではありません。



実装と検証記録を公開
詳しい説明はチラシでも読めます。
github.com/mani1261790/ToolUseProxy

デモ収録 14分52秒 / 保存済みログ 40件
研究開発アルファ版 / 2026-09-25時点